



Báo cáo bài thi cuối kì

Môn học : Học Máy

Đề tài:

**MÔ HÌNH HỌC MÁY DỰ ĐOÁN
KHẢ NĂNG MẮC BỆNH TIM**


Thành viên Nhóm 9 :

Đỗ Đình An - 2351170568

Mã Khánh Linh - 2351170602

Trần Ngọc Lương - 2351170604

Giảng viên hướng dẫn: TS. Tạ Quang Chiểu



NỘI DUNG



01 Quan sát dữ liệu

02 Khám phá dữ liệu

03 Huấn luyện mô hình
Logistic Regression

04 Huấn luyện mô hình
K-Nearest Neighbors

05 Tối ưu hóa thuật toán










06 Phân tích đánh giá kết
quả mô hình đạt được.

07 Kết luận



01. Quan sát dữ liệu

- Age : Phân phối lệch trái nhẹ, tập trung nhiều ở nhóm 50–60 tuổi – đây là độ tuổi có nguy cơ mắc bệnh tim cao nhất.
- Sex : Nam giới chiếm tỷ lệ lớn hơn rõ rệt so với nữ, cho thấy bệnh tim phổ biến hơn ở nam.
- CP : Biến phân loại với các mức độ đau khác nhau; nhóm có kiểu đau điển hình chiếm tỷ lệ cao trong nhóm mắc bệnh tim.
- Trestbps : Phân phối gần chuẩn, trung tâm khoảng 130–140 mmHg.
- Chol : Lệch phải rõ rệt – một số trường hợp có cholesterol rất cao
- Thalach: Phân phối chuẩn, trung bình khoảng 150 bpm; người mắc bệnh tim thường có nhịp tim tối đa thấp hơn.
- Oldpeak : Lệch phải; đa số giá trị thấp nhưng có một số trường hợp rất cao, thể hiện nguy cơ bệnh nặng hơn.
- Exang : Phần lớn người không bị đau khi gắng sức, nhưng trong nhóm bị bệnh tim, tỷ lệ đau khi gắng sức cao hơn rõ.
- Target : Phân bố tương đối cân bằng giữa hai nhóm 0 và 1.









02. Khám phá dữ liệu

- *target* tương quan mạnh với *cp* (0.43) và *thalach* (0.42) → đau ngực điển hình, nhịp tim cao → ít nguy cơ bệnh tim.
- Tương quan âm với *exang*, *oldpeak* (-0.44), *ca* (-0.38), *thal* (-0.34) → giá trị cao làm tăng nguy cơ bệnh tim.
- Các biến độc lập tương quan thấp → ít đa cộng tuyến.
- *age* và *thalach* tương quan âm (-0.39) → tuổi cao, nhịp tim tối đa thấp.
- *oldpeak* và *slope* âm mạnh (-0.58) → ST chênh cao, độ dốc thấp.
- Đa số biến khác tương quan yếu (<0.3) → ảnh hưởng nhỏ đến *target*.



✓ Kết luận:


Các yếu tố quan trọng nhất ảnh hưởng đến bệnh tim trong dữ liệu này là: *cp*, *thalach*, *exang*, *oldpeak*, *ca*, *thal* – trong đó *cp* và *thalach* tác động tích cực, còn bốn biến còn lại tác động tiêu cực đến khả năng có bệnh tim.





- **Age vs Target** : Nguy cơ bệnh tim tăng theo tuổi, phù hợp với thực tế y học khi thành mạch dần xơ cứng theo thời gian.
- **trestbps và Target** : Nhóm người mắc bệnh tim có xu hướng huyết áp trung bình cao hơn, thể hiện qua giá trị trung vị lớn hơn trong biểu đồ.
- **chol và Target** : cholesterol cao góp phần làm tăng nguy cơ, nhưng không phải yếu tố quyết định duy nhất.
- **thalach và Target** : khả năng tim bơm máu khỏe hơn và sức bền tim mạch tốt hơn ở nhóm không bệnh.
- **oldpeak và Target** : Giá trị oldpeak cao hơn rõ rệt ở nhóm mắc bệnh tim, cho thấy độ chênh sóng ST (dấu hiệu thiếu máu cơ tim) thường lớn. Đây là một biến lâm sàng rất quan trọng trong chẩn đoán bệnh tim thiếu máu cục bộ.





03. Logistic Regression

Trong bài toán này, biến phụ thuộc là target (1 = có bệnh tim, 0 = không bệnh tim), còn các biến độc lập bao gồm các chỉ số sinh học và nhân khẩu học như age, trestbps, chol, thalach, oldpeak, ca, sex, cp, v.v...
Mục tiêu là xây dựng mô hình hồi quy tuyến tính giúp ước lượng xác suất mắc bệnh tim dựa trên các yếu tố đầu vào này.

1

Chuẩn hóa dữ liệu

Vì các biến như chol (cholesterol), trestbps (huyết áp), và thalach (nhịp tim) có thang đo rất khác nhau, ta cần chuẩn hóa dữ liệu. Phương pháp chuẩn hóa phổ biến là StandardScaler – chuyển các biến về trung bình 0 và độ lệch chuẩn 1, giúp mô hình học hiệu quả hơn và tránh hiện tượng một biến chi phối toàn bộ mô hình.

2


Huấn luyện mô hình

Sau khi chuẩn hóa dữ liệu, ta sử dụng tập huấn luyện để huấn luyện mô hình hồi quy tuyến tính. Mô hình sẽ tìm ra các hệ số hồi quy ($\beta_1, \beta_2, \dots$) biểu thị mức độ ảnh hưởng của từng yếu tố đến khả năng mắc bệnh tim.

3

Đánh giá mô hình

Sau khi huấn luyện, mô hình được đánh giá bằng các chỉ số: Accuracy, Precision / Recall, F1-score
Nếu độ chính xác chưa tốt, có thể tăng số vòng lặp, tinh chỉnh learning rate, hoặc thêm đặc trưng quan trọng hơn.



So sánh Huấn luyện Mô hình và dùng thư viện Sklearn

- **Về độ chính xác (Accuracy):**

Hai mô hình cho kết quả tương đương nhau (sai khác rất nhỏ, chỉ vài phần trăm).

- **Về Precision và Recall:**

Các chỉ số này cũng gần bằng nhau, chứng tỏ mô hình được huấn luyện đã học được ranh giới phân loại tương tự với mô hình của thư viện.


- **Về F1-Score:**

Cả hai mô hình đạt mức F1 tương đồng → khả năng cân bằng giữa Precision và Recall là như nhau.

- **Về tốc độ và tính ổn định:**


Mô hình huấn luyện cần nhiều vòng lặp để hội tụ, chậm hơn và dễ bị ảnh hưởng bởi tham số `learning_rate`.

Mô hình Scikit-learn sử dụng các thuật toán tối ưu nâng cao (như LBFGS, SAG...) → hội tụ nhanh, ổn định hơn.



04. K-Nearest Neighbors (KNN)

What class does the new data point belong to?



Mục tiêu là xây dựng mô hình K-Nearest Neighbors (KNN) nhằm dự đoán khả năng mắc bệnh tim dựa trên các điểm dữ liệu tương tự trong không gian đặc trưng.

01 - Chuẩn hóa dữ liệu

Phương pháp phổ biến là StandardScaler, giúp chuyển các đặc trưng về trung bình 0 và độ lệch chuẩn 1. Nhờ đó, khoảng cách Euclidean giữa các điểm trở nên chính xác và công bằng hơn.

02 - Huấn luyện mô hình

Khi có dữ liệu chuẩn hóa, ta chọn số láng giềng K (ví dụ K=5).


- Tính khoảng cách Euclidean giữa mẫu mới và tất cả các mẫu trong tập huấn luyện.
- Chọn K điểm gần nhất (K láng giềng).
- Thực hiện bỏ phiếu đa số (Majority Vote) để quyết định nhãn dự đoán.

03 - Đánh giá mô hình

Sau khi huấn luyện, mô hình được đánh giá bằng các chỉ số: Accuracy, Precision, Recall, F1-Score.

So sánh Huấn luyện Mô hình và dùng thư viện Sklearn

Tất cả các chỉ số đều bằng nhau gần như tuyệt đối, cho thấy mô hình tự code hoạt động chính xác tương đương với Scikit-learn.



- **Ưu điểm của mô hình tự code:**

Giúp hiểu rõ cơ chế hoạt động của thuật toán KNN (tính khoảng cách, chọn K lân cận, bỏ phiếu...).
Dễ tùy chỉnh logic cho các mục đích đặc biệt.

- **Ưu điểm của thư viện Scikit-learn:**

Dễ sử dụng, nhanh hơn nhờ tối ưu hóa nội bộ.
Có sẵn nhiều tùy chọn (khoảng cách, trọng số, cross-validation...).

➔ **Kết luận:**

Về kết quả, hai cách cho độ chính xác tương đương, nhưng dùng Scikit-learn là lựa chọn tối ưu hơn trong thực tế vì hiệu năng và tiện lợi, còn tự code phù hợp để học thuật và nghiên cứu cơ chế thuật toán.

05. Tối ưu thuật toán

Để tìm ra mô hình tốt nhất, nhóm sử dụng kỹ thuật Grid Search K - cross validation (5 fold CV).
Tiêu chí đánh giá chính để chọn tham số tối ưu là F1 - score vì F1 cân bằng giữa precision và recall.

Tối ưu hóa thuật toán Logistic Regression sử dụng GridSearchCV với 5-Fold CV :

- Tham số cần tối ưu : Tham số C (tham số điều chỉnh), với C càng nhỏ thì mức độ trừng phạt càng mạnh, giúp chống Overfitting.
- Không gian tìm kiếm : C thuộc {0.01, 0.1, 1, 10, 100}.
- Kết quả tối ưu : Tham số C tối ưu được tìm thấy là C = [0.1]

```
Bắt đầu chạy Grid Search cho KNN...
=====
KNN: Tham số K tối ưu (CV F1-score): 1
KNN: F1-Score trung bình (5-Fold CV): 0.9640
=====
```

Tối ưu hóa thuật toán K - Nearest Neighbors (KNN) sử dụng GridSearchCV với 5-Fold CV :

- Tham số cần tối ưu : Tham số n_neighbors (giá trị K), là số lượng láng giềng gần nhất được sử dụng để đưa ra quyết định.
- Không gian tìm kiếm : K thuộc {1, 3, 5, ..., 25}.
- Kết quả tối ưu : Tham số K tối ưu được tìm thấy là K = [1].



```
Bắt đầu chạy Grid Search cho Logistic Regression...
=====
Logistic Regression: Tham số C tối ưu (CV F1-score): 0.1
Logistic Regression: F1-Score CV tốt nhất (5-Fold CV): 0.8574
=====
```



Đánh giá mô hình

1. Biểu đồ so sánh hiệu suất mô hình (Accuracy, Precision, Recall, F1-Score)


- KNN hoạt động tốt hơn về khả năng phân loại đúng bệnh nhân mắc và không mắc bệnh tim.
- Tuy nhiên, KNN với K=1 có thể bị nhạy cảm với nhiễu (overfitting) vì chỉ dựa vào láng giềng gần nhất.
- Logistic Regression có hiệu suất ổn định hơn, phù hợp khi muốn mô hình dễ diễn giải và tổng quát tốt



2. Ma trận nhầm lẫn (Confusion Matrix – Logistic Regression)

Nhìn chung, Logistic Regression phân loại khá chính xác, tuy vẫn còn một số trường hợp dương tính giả cần giảm bằng cách tinh chỉnh ngưỡng xác suất hoặc thêm đặc trưng đầu vào.

06. Phân tích đánh giá kết quả mô hình đạt được.



Mục tiêu và chiến lược đánh giá

Mục tiêu cốt lõi của việc đánh giá là xác định mô hình có khả năng tổng quát hóa tốt nhất trên dữ liệu chưa được thấy (Test Set). Trong lĩnh vực y tế, ưu tiên hàng đầu là giảm thiểu False Negative (FN) - tức là số lượng bệnh nhân thực sự mắc bệnh bị dự đoán nhầm là khỏe mạnh, nhằm đảm bảo sự an toàn cho bệnh nhân

Chọn thuật toán phù hợp với mô hình và phân tích tối ưu tham số

Với tập dữ liệu heart-disease.csv, thuật toán KNN cho độ chính xác cao hơn Logistic Regression, nên được chọn làm mô hình chính.

Quá trình tối ưu tham số bằng Grid Search Cross-Validation (5-Fold CV) cho kết quả:

Logistic Regression: $C = 0.1$

KNN: $K = 1$

Nhận xét: F1-Score cao nhất tại $K = 1$ cho thấy mô hình phân biệt tốt nhưng có nguy cơ overfitting, cần cân nhắc khi áp dụng cho dữ liệu thực tế.



06. Phân tích đánh giá kết quả mô hình đạt được.




Đánh giá

Mô hình tốt nhất : KNN ($K = 1$) được chọn là mô hình dự đoán khả năng mắc bệnh tim tối ưu nhất đạt được trong dự án này. Mô hình này không chỉ đạt **F1-Score** cao nhất (99.04%)

Rủi ro : Mặc dù **KNN** cho kết quả gần như tuyệt đối, nhưng mà giá trị $K = 1$ có thể dẫn đến rủi ro **Overfitting**. Trong các ứng dụng thực tế, mô hình này cần được kiểm tra thêm với các kỹ thuật kiểm định chéo phức tạp hơn để xác nhận tính tổng quát hóa.

Hạn chế của Logistic Regression : Đã bị loại bỏ do hiệu suất thấp hơn và tỉ lệ lỗi FN cao hơn.



07. Kết luận

- **Nhận xét:**

Hai thuật toán chính được đưa vào so sánh là Logistic Regression và KNN (K-Nearest Neighbors). Qua quá trình thực nghiệm, kết quả đã chỉ ra rằng mô hình KNN mang lại hiệu suất dự đoán vượt trội hơn trong bối cảnh của bộ dữ liệu này.

Kết quả của dự án cũng nhấn mạnh một yếu tố then chốt: chất lượng của dữ liệu đầu vào. Hiệu suất của mô hình phụ thuộc trực tiếp vào tính đầy đủ, đa dạng và chính xác của dữ liệu.

Nhìn chung, dự án đã đạt được mục tiêu đề ra, mang lại kinh nghiệm quý báu và chứng minh tính hiệu quả của các thuật toán học máy trong việc hỗ trợ sàng lọc sớm bệnh tim mạch.

- **Hạn chế:**

Mới so sánh hai thuật toán cơ bản, chưa thử các mô hình mạnh hơn (Ensemble, Deep Learning).

Dữ liệu còn hạn chế về số lượng và đặc trưng, ảnh hưởng đến khả năng tổng quát hóa.


- **Hướng phát triển:**

Mở rộng dữ liệu và bổ sung thêm biến liên quan đến bệnh tim.

Thử nghiệm thuật toán nâng cao như Random Forest, SVM.

Đánh giá toàn diện bằng K-Fold CV và tinh chỉnh siêu tham số.

Phát triển hệ thống dự đoán thời gian thực, có khả năng cập nhật mô hình khi có dữ liệu mới.



**THANK FOR
LISTENING**

